

Machine Learning para Diagnóstico de Câncer de Mama

Comparação de Modelos com Grid Search

Beatriz Alves Gava · Wallace Miranda Senna da Silva

Disciplina: Machine Learning – 17/06/2026




Definição do Problema e Dados

O Problema

Classificar tumores de mama como **benignos** ou **malignos** com base em características extraídas de imagens de biópsia — auxiliando o diagnóstico médico e reduzindo falsos negativos, que são críticos neste contexto clínico.

i Dataset: **Wisconsin Breast Cancer** — 569 amostras, 30 atributos numéricos derivados de imagens digitalizadas de células tumorais.

Distribuição das Classes



62,7% benigno · 37,3% maligno — dataset levemente desbalanceado, reforçando a importância do F1-Score como métrica principal.

Metodologia



Pré-processamento

- **StandardScaler**: normalização dos 30 atributos
- Divisão: **60% treino** / 20% validação / 20% teste

Ajuste de Hiperparâmetros

- **GridSearchCV** com 5-fold cross-validation
- Métrica de otimização: **F1-Score**

Métricas Avaliadas


- Acurácia, Precisão, Recall
- F1-Score, AUC
- Matriz de Confusão

Resultados no Conjunto de Teste

Modelo	AUC	F1-Score	Precisão	Recall	Acurácia
Regressão Logística	0.9976	0.979	0.972	0.986	0.974
Árvore de Decisão	0.955	0.944	0.944	0.944	0.944
Random Forest	0.994	0.958	0.958	0.958	0.958

✔ **Destaque:** A Regressão Logística obteve o melhor desempenho geral — AUC de **0.9976** e F1-Score de **0.979** — superando modelos mais complexos.

Comparativo de Desempenho — Conjunto de Teste



Todos os modelos superam **94%** em todas as métricas avaliadas. A **Árvore de Decisão** apresenta leve queda de desempenho em relação aos demais, possivelmente devido a overfitting residual mesmo após a otimização via Grid Search. A Regressão Logística lidera em todas as dimensões.

Matrizes de Confusão e Curvas ROC

Interpretação das Matrizes de Confusão

Os três modelos apresentam **poucos falsos negativos** — casos malignos classificados erroneamente como benignos. Essa métrica é **crítica no diagnóstico de câncer**, pois um falso negativo pode atrasar o tratamento e comprometer o prognóstico do paciente.

⚠ Falsos negativos são o erro mais custoso neste domínio clínico. O alto Recall da Regressão Logística (0.986) minimiza esse risco.

Curvas ROC e AUC

Valores de AUC próximos de 1.0 indicam excelente poder de discriminação entre tumores benignos e malignos. A Regressão Logística alcança AUC de **0.9976**, demonstrando que o modelo é capaz de separar as classes com altíssima confiança em praticamente todos os limiares de decisão.

AUC 0.9976

Regressão Logística

AUC 0.994

Random Forest

AUC 0.955

Árvore de Decisão

Melhores Hiperparâmetros — Grid Search

Os hiperparâmetros abaixo foram selecionados pelo **GridSearchCV** com 5-fold cross-validation, otimizando o F1-Score no conjunto de validação.



Regressão Logística

- `C = 1` — regularização padrão, evita overfitting sem penalizar excessivamente
- `penalty = l2` — regularização Ridge, adequada para dados com muitos atributos correlacionados



Árvore de Decisão

- `max_depth = 5` — limita a profundidade para controlar overfitting
- `min_samples_split = 5` — exige ao menos 5 amostras para dividir um nó



Random Forest

- `n_estimators = 200` — 200 árvores no ensemble para maior estabilidade
- `max_depth = 10` — profundidade moderada para equilibrar bias e variância

Conclusões e Possíveis Melhorias

Conclusões

→ Simplicidade vence

A Regressão Logística superou modelos mais complexos — indicando que os dados do Wisconsin Breast Cancer são **linearmente separáveis**.

→ Grid Search eficaz

A otimização de hiperparâmetros melhorou marginalmente o desempenho em relação às configurações padrão dos modelos.

→ Random Forest robusto

Apresenta bom desempenho, porém com **maior custo computacional** sem ganho proporcional de acurácia neste dataset.

Possíveis Melhorias

Redução de Dimensionalidade


Aplicar **PCA** para reduzir os 30 atributos e avaliar impacto no desempenho e interpretabilidade.

Redes Neurais

Testar arquiteturas simples com **TensorFlow/Keras** para verificar ganhos em datasets maiores.

Mais Dados

Coletar dados externos para **validação cruzada** em populações distintas e aumentar a generalização.



Repositório do Projeto

Todo o código-fonte, notebooks, dados e resultados estão disponíveis publicamente no GitHub para reprodução e extensão dos experimentos.

 **Repositório GitHub:**

github.com/beatrizgava/ml-breast-cancer-diagnosis

Notebooks Jupyter

Análise exploratória, pré-processamento e treinamento dos modelos documentados passo a passo.

Grid Search Logs

Resultados completos do GridSearchCV com todas as combinações de hiperparâmetros testadas.

Visualizações

Matrizes de confusão, curvas ROC e gráficos comparativos de métricas exportados em alta resolução.

Beatriz Alves Gava · Wallace Miranda Senna da Silva — Machine Learning, 17/06/2026

